Arquitectura con el uso de IA

Arquitectura con el uso de IA

EMPRESA_JOSESAID · estado al 9 de noviembre de 2026 · complementa «Arquitectura actual» (revisión del 30 de octubre de 2026)

1. Resumen

Los 11 microservicios de negocio, identidad e infraestructura siguen igual. La IA se agregó como una capa nueva: **nexus-ms** (asistente con Spring AI y Claude) y **nexus-comun** (filtros, registro de tokens, prompts y evaluaciones). Nexus solo lee datos y propone; las escrituras pasan por confirmación humana. El piloto por áreas verificó **22 de 22** respuestas contra el dato que devuelve cada servicio.

2. Lo que se implementó como IA

Componente	Qué hace	Por qué
nexus-ms · asistente con Spring AI	Responde preguntas y llama herramientas de los servicios.	Un solo punto de entrada para IA; ningún servicio habla con el modelo directo.
Herramientas por servicio (67 registradas)	Lecturas y propuestas de clientes, ventas, compras, contabilidad, inventario, documentos, facturación, reportes y usuarios.	El modelo usa lo que el servicio ya expone; no hay lógica de negocio nueva en la IA.
Acciones pendientes con confirmación	Toda escritura queda como borrador con código de 8 dígitos y caduca si no se confirma.	Una escritura automática sin revisión humana no es aceptable en contabilidad ni compras.
Mismo JWT del usuario y filtro por rol	Cada consulta corre con el token de quien pregunta; `AlcanceHerramientas` oculta lo que su rol no puede usar.	La IA no crea permisos nuevos: ve y hace lo mismo que la persona en la plataforma.
Filtro de datos sensibles (nexus-comun)	Redacta datos personales antes de enviar texto al modelo.	Ajustado tras el piloto (PR #169): el patrón de teléfono confundía dígitos de los UUID.
RAG de políticas	Busca fragmentos de políticas (embeddings Voyage, pgvector de 1024 dimensiones) y responde citando la política.	La respuesta sale de un texto aprobado, no de lo que el modelo supone.
Sugeridor de pólizas (`sugerir_poliza`)	Propone una póliza balanceada; se registra solo al confirmarla.	Contabilidad sigue siendo decisión humana; la IA ahorra captura, no el registro.
Límite de herramientas por pregunta	`NEXUS_MAX_HERRAMIENTAS` (por defecto 4) acota las llamadas por respuesta.	Controla costo y latencia de cada consulta.
Presupuesto de tokens por usuario	Por defecto 15 000 tokens; al agotarse, la consulta se detiene. Cada corrida se registra en nexus-comun.	Evita gasto sin control; el piloto lo agotó varias veces y se ajustó solo para esas corridas.
Auditoría de consultas	Guarda cada pregunta y las herramientas usadas.	Trazabilidad de quién preguntó qué y qué datos salieron.

Servidor MCP (`/mcp`)	Expone las herramientas a clientes externos con el token del usuario.	Permite usar las mismas herramientas desde otro cliente sin relajar permisos.
Prompts versionados y evaluaciones	Prompts en versiones v1 y v2 con casos de evaluación y línea base.	Cada cambio de prompt se puede medir contra los mismos casos.

3. Ajustes a los servicios de negocio

Ningún servicio cambió su lógica por IA. Lo que sí cambió es qué endpoints se exponen a Nexus. El catálogo registra 101 endpoints; 94 aplican a IA y 66 (70 %) ya tienen herramienta.

Servicio	Estado con IA	Qué se expone y qué queda fuera
clientes-ms	**Lectura y prospectos**	Búsqueda, ficha, interacciones, métricas y prospectos. Sin consentimientos ni cambio de estatus.
pedidos-ventas-ms	**La más completa**	Cotizaciones, pedidos, devoluciones y resumen de ventas. Sin entrega.
compras-proveedores-ms	**Parcial**	Proveedores, órdenes, recepciones y cancelación. Sin aprobación de orden.
contabilidad-ms	**Parcial**	Catálogo, pólizas (vía sugerencia y confirmación) y estados financieros. Sin altas de cuenta ni cierre de periodo, por decisión.
facturacion-pagos-ms	**Parcial**	Consultas, cobranza y pagos registrados con confirmación. Sin emisión ni cancelación de comprobantes.
inventario-operaciones-ms	**Parcial**	Existencias, trazabilidad de lote, bajo mínimo y movimientos. Sin alta de almacenes ni cierre de orden.
documentos-cumplimiento-ms	**Parcial**	Consultas, vencimientos y solicitud de eliminación. Sin alta, versiones ni descarga.
reportes-ejecutivos-ms	**Parcial**	Indicadores y reporte por periodo. Sin cierre de periodo ni exportación.
usuarios-accesos-ms	**Mínima**	Solo listar y consultar usuarios. Roles, área y baja quedan fuera por decisión; fuera de alcance del piloto.
gateway, discovery, auth	**Sin cambios**	Siguen como infraestructura. Nexus los usa solo para enrutar y autenticar.

> El catálogo de endpoints tiene dos cifras que no cuadran: el resumen dice 66 cubiertos y la suma de los encabezados por servicio da 44. Hay que revisarlo antes de dar el número como definitivo.

4. Estado frente al plan original

Elemento del plan	Estado	Nota
Fase 0 · Cimientos (nexus-comun)	**Implementada**	Filtro, registro de tokens, prompts y evaluaciones.
Fase 1 · Consulta de reportes y clientes	**Implementada**	Herramientas de lectura por rol.

Fase 2 · RAG de compras	**Implementada**	Política de aprobación de órdenes de compra indexada.
Fase 3 · Cuentas contables	**Implementada**	Como sugerencia de póliza; no crea cuentas.
Fase 4 · Servidor MCP	**Implementada**	En `/mcp`, con el token del usuario.
Fase 5 · Agentes	**No se crea**	Decisión: un asistente único basta; los agentes multiplicarían el gasto de tokens.
Fase 6 · Interfaz	**Pendiente**	El endpoint de chat existe (`POST /nexus/consultas`); falta decidir si será web propia o Teams/Slack.
Extracción de datos de documentos	**No implementada**	Era propuesta; hoy solo hay consultas y solicitud de eliminación.
Explicación de alertas de inventario	**No implementada**	Era propuesta; hoy hay consultas de existencias y bajo mínimo.

5. Pendientes

- **Interfaz de Nexus:** web propia o canal existente (Teams o Slack).
- **Presupuesto de tokens:** decidir si los 150 000 del piloto se vuelven permanentes o se mantienen en 15 000.
- **Fechas de Nexus:** mostrar hora de Ciudad de México en vez de UTC.
- **Datos al modelo:** confirmar si se permite enviar datos aun redactados.
- **Catálogo de endpoints:** conciliar las cifras de cobertura (66 frente a 44).

> **Regla de seguridad vigente:** Nexus solo lee datos. Cualquier cambio que proponga el modelo llega como borrador, caduca si no se confirma y se ejecuta únicamente con el código de confirmación de la persona.